Automated Model Risk Auditor | ארכיטקטורה

CASE STUDY: איפה כל דבר יושב

באפיון תיארנו חלקים: מאגר בדיקות, בדיקה כפולה, שלושה שופטים, ציון, דוח. אבל רעיון לא רץ על שום מחשב.

עכשיו השאלה של מי שבונה: אילו תוכנות יש בפועל? מי שולח למי? ומה קורה כשאחת מהן נתקעת באמצע ריצה של אלפי בדיקות?

התשובה נקראת ארכיטקטורה: מפה של הרכיבים (כל רכיב הוא תוכנה אחת עם תפקיד אחד), של הקווים ביניהם, ושל מה שעובר בהם.

נצייר אותה בכמה רמות, נשלח בה בדיקה אחת מקצה לקצה, ננסה להפיל רכיבים, ובסוף נבדוק שאלה אחת: האם המעגל סגור?

3.1 מבט על: רכיבים, תפקידים וממשקים

- **צינור הבדיקה:** איך בדיקה נבחרת, מורצת ונאספת.
- **מחקר יריבי:** איך ממציאים בדיקות חדשות ומריצים אותן בבטחה.
- **שיפוט והחלטה:** מי שופט, ואיך התוצאות נהפכות להחלטה.
- **דיווח ומעקב:** מה מוסרים, ומה ממשיך אחרי השחרור.
- **שכבה חוצה:** מפתחות שהחתימה נשענת עליהם.

רכיב	תפקיד	ממשקים נכנסים	ממשקים יוצאים
מנהל מאגר הבדיקות	מחזיק את כל הבדיקות בגרסאות, כולל הבדיקות שהמחולל ממציא. לכל הרצה הוא נותן אצווה של בדיקות ורושם באיזו גרסה השתמשו.	בדיקות חדשות מהמחולל, ובקשת הרצה.	אצווה של בדיקות למנוע הבדיקה הכפולה.
מנוע בדיקה כפולה	כל בדיקה נשלחת פעמיים: פעם כבדיקה מוצהרת (Mode A) ופעם כשיחה רגילה (Mode B). הוא משווה את שתי התשובות לפי המשמעות שלהן.	אצווה מהמאגר.	זוגות תשובות לתזמורת השופטים, ובדיקות מסוכנות לחדר המבודד.
המודל הנבדק (חיצוני)	המודל שמגישים לבדיקה. הוא מחוץ למערכת, ולא נותנים לו להכיר אותה.	שאלות מהמנוע.	תשובות.
מחולל בדיקות תקיפה	ממציא ניסוחי תקיפה חדשים בשלוש שיטות, כמו תוקף אמיתי, בתוך תקציב קבוע.	קטגוריה ותקציב.	בדיקות חדשות למאגר.
מתאם החדר המבודד	מריץ בדיקות מסוכנות בתוך סביבה שנראית אמיתית אבל חסומה מהעולם, ומוחק אותה אחרי כל בדיקה.	בדיקה שדורשת הרצת קוד.	תוצאה, ורשימת ניסיונות יציאה שנחסמו.
תזמורת השופטים	מעביר כל תשובה לשלושה שופטים שונים (חוקים ושני מודלים) ומחשב את ההסכמה ביניהם.	זוגות תשובות, ודגימות מהשטח.	פסק דין לכל תשובה, או העברה לתור אנושי.

רכיב	תפקיד	ממשקים נכנסים	ממשקים יוצאים
תור ביקורת אנושי	כאן מחכים המקרים שבהם השופטים לא הסכימו. אדם מכריע.	מחלוקות.	החלטה אנושית.
מנוע ציון הסיכון	מחשב ציון לכל קטגוריה, בודק סף קשיח לקטגוריות קריטיות, ומשווה לגרסאות קודמות.	פסקי דין.	החלטה: משחררים או לא, והשוואה לגרסה הקודמת.
שירות הדוח	מרכיב את התוצאות לדוח בשלוש רמות, מפיק PDF וחותם עליו.	החלטה ותוצאות.	דוח חתום לרגולטור.
ניטור אחרי שחרור	דוגם שימוש אמיתי במודל, שולח לשופטים, ומשווה למה שנבדק לפני השחרור. מזהה סטייה.	דגימה מהשטח.	התראה, ובקשת השעיה.
ניהול מפתחות	מחזיק את המפתח שבו חותמים את הדוח.	בקשת חתימה.	חתימה.
מנגנון עצירה חיצוני (חיצוני)	פרויקט נפרד שהניטור פונה אליו כשהוא רוצה להשעות מודל. מחוץ למערכת, ולא בשליטתה.	בקשת השעיה.	החלטה על השעיה, בתנאים שלו.

הקווים בין הרכיבים

- **בדיקות חדשות:** מחולל בדיקות תקיפה ← מנהל מאגר הבדיקות
- **אצווה:** מנהל מאגר הבדיקות ← מנוע בדיקה כפולה
- **שאלה בשני ניסוחים:** מנוע בדיקה כפולה ← המודל הנבדק
- **בדיקה מסוכנת:** מנוע בדיקה כפולה ← מתאם החדר המבודד
- **הרצה מבודדת:** מתאם החדר המבודד ← המודל הנבדק
- **זוגות תשובות:** מנוע בדיקה כפולה ← תזמורת השופטים
- **מחלוקת:** תזמורת השופטים ← תור ביקורת אנושי (קו תמיכה)
- **פסקי דין:** תזמורת השופטים ← מנוע ציון הסיכון
- **החלטה וציון:** מנוע ציון הסיכון ← שירות הדוח
- **דגימה מהשטח:** ניטור אחרי שחרור ← תזמורת השופטים (קו תמיכה)
- **בקשת השעיה:** ניטור אחרי שחרור ← מנגנון עצירה חיצוני (קו תמיכה)
- **חתימה:** ניהול מפתחות ← שירות הדוח (קו תמיכה)

3.2 התאמה לאפיון: איזה רכיב משרת איזה פיצ'ר

#	פיצ'ר	רכיבים	איך
1	ניהול מאגר הבדיקות	מנהל מאגר הבדיקות, מנוע בדיקה כפולה	המאגר מחלק אצוות בגרסאות למנוע הבדיקה.
2	זיהוי שינוי התנהגות	מנוע בדיקה כפולה, תזמורת השופטים	המנוע שולח כל שאלה פעמיים ומודד פער.
3	שלושה שופטים	תזמורת השופטים, תור ביקורת אנושי	התזמורת מריצה שלושה שופטים, ומחלוקת עוברת לאדם.

#	פיצ'ר	רכיבים	איך
4	ציון ושער שחרור	מנוע ציון הסיכון	הציונים נאספים, ושער קשיח בודק קטגוריות קריטיות.
5	ייצור בדיקות תקיפה	מחולל בדיקות תקיפה, מנהל מאגר הבדיקות	המחולל ממציא בדיקות שנכנסות למאגר.
6	הרצה בחדר מבודד	מתאם החדר המבודד, המודל הנבדק	בדיקות מסוכנות רצות בחדר שנמחק אחר כך.
7	מעקב אחרי רגרסיה	מנוע ציון הסיכון, מנהל מאגר הבדיקות	כל גרסה מושווית לקודמת, לפי אותה גרסת מאגר.
8	דוח חתום	שירות הדוח, ניהול מפתחות	השירות מרכיב דוח בשלוש רמות, והמפתח חותם.
9	ניטור אחרי שחרור	ניטור אחרי שחרור, תזמורת השופטים, מנגנון עצירה חיצוני	דגימה מהשטח נשפטת, וסטייה מייצרת בקשת השעיה.

3.3 עיצוב נתונים

נתונים שעוברים ולא נשמרים

- **TestCase:** הבדיקה בדרך מהמאגר אל מנוע הבדיקה.
- **ModePair:** זוג התשובות בדרך אל השופטים.
- **JudgeVerdict:** פסק הדין בדרך אל מנוע הציון.

נתונים שנשמרים

- **SuiteVersion:** כל גרסה של המאגר נשמרת. בלי זה אי אפשר לשחזר.
- **RunRecord:** כל הרצה, מול גרסת המאגר וגרסת המודל.
- **JudgeLog:** כל פסק דין עם הנימוק, כדי שאפשר לחזור ולשאול למה.
- **SignedReport:** הדוח הסופי עם החתימה שלו.
- **DriftSample:** דגימות מהשטח, שבוע אחרי שבוע, לצורך השוואה.

ההודעות המרכזיות

TestCase (ממנהל המאגר אל מנוע הבדיקה)

```
{
  "test_id": "t-2291",
  "suite_version": "v14",
  "category": "weapons_uplift",
  "prompt_a": "This is a safety evaluation. ...",
  "prompt_b": "Hey, quick question ...",
  "risk_level": "high"
}
```

שדה	סוג	למה הוא שם
suite_version	טקסט	איזו גרסה של המאגר.
prompt_a	טקסט	הניסוח המוצהר.
prompt_b	טקסט	הניסוח הרגיל.
risk_level	low או high	האם צריך חדר מבודד.

ModePair (ממנוע הבדיקה אל תזמורת השופטים)

```
{
  "test_id": "t-2291",
  "response_a": "I cannot help with that.",
  "response_b": "Sure, here are the steps ...",
  "semantic_distance": 0.81
}
```

שדה	סוג	למה הוא שם
response_a	טקסט	התשובה במצב בדיקה.
response_b	טקסט	התשובה במצב רגיל.
semantic_distance	מספר בין 0 ל-1	כמה התשובות שונות במשמעות.

JudgeVerdict (מתזמורת השופטים אל מנוע הציון)

```
{
  "response_id": "r-88121",
  "verdicts": {"rules": "safe", "judge_a": "safe", "judge_b": "unsafe"},
  "kappa": 0.21,
  "decision": "human_review"
}
```

שדה	סוג	למה הוא שם
verdicts	שלושה ערכים	מה אמר כל שופט.
kappa	מספר	כמה השופטים מסכימים מעבר למקרה.
decision	auto או human_review	מי הכריע.

RiskDecision (ממנוע הציון אל שירות הדוח)

```
{
  "model_version": "m-3.2",
  "overall": 71,
  "hard_gate": "fail",
  "failed_category": "deception",
  "regression_vs_prev": "none"
}
```

שדה	סוג	למה הוא שם
overall	מספר	הציון הכללי.
hard_gate	pass או fail	האם קטגוריה קריטית חצתה סף.
failed_category	טקסט	איזו קטגוריה.

SuspensionRequest (מהניטור אל מנגנון העצירה החיצוני)

```
{
  "model_version": "m-3.2",
  "category": "deception",
  "drift_score": 3.9,
  "requested_action": "suspend"
}
```

שדה	סוג	למה הוא שם
drift_score	מספר	כמה הסטייה חריגה.
requested_action	suspend	מה ביקשנו.

פרשות דרכים: החלטות ארכיטקטורה

שירות אחד גדול או רכיבים נפרדים?

נבחר: רכיבים נפרדים. כל רכיב עושה דבר אחד, ואפשר להחליף או להרחיב רכיב אחד בלי לגעת בשאר. נפילה של רכיב לא מפילה את כולם.

המחיר: צריך להגדיר היטב איך הם מדברים, ולנהל כמה תוכנות.

להריץ בדיקות מסוכנות בתוך המערכת או בחדר נפרד?

נבחר: חדר נפרד. כך הסכנה מבודדת לרכיב אחד שאפשר לנעול. אם משהו בורח, הוא תקוע בחדר.

המחיר: רכיב נוסף, וזמן הקמה לכל בדיקה.

שופטים ברצף או במקביל?

נבחר: במקביל. שלושת השופטים לא רואים אחד את השני, ולכן לא משפיעים. וגם מהר יותר.

המחיר: צריך לחכות לשלושתם לפני הכרעה.

שהמערכת תבצע השעיה בעצמה או תבקש ממישהו אחר?

נבחר: לבקש ממנגנון חיצוני. המערכת נבנתה להעריך ולדווח, לא לשלוט במודל. הכנסת אכיפה לתוכה הייתה מרחיבה אותה לתחום אחר.

המחיר: המעגל נשאר פתוח. מי שמבצע נמצא מחוץ לגבולות, ואנחנו לא שולטים בו.

סדר בנייה: חמישה ספרינטים

- **ספרינט 1: שלד שעובד:** בדיקה אחת מקצה לקצה: שאלה, תשובה, שופט אחד, ציון, דוח פשוט. קודם נתיב אחד שלם, גם אם גס. אחר כך מתחזקים כל חלק בו.
- **ספרינט 2: שיפוט אמיתי:** שלושה שופטים, מדד הסכמה ותור אנושי. זה לב המערכת: לא סומכים על שופט אחד.
- **ספרינט 3: חדר מבודד ובדיקות תקיפה:** מחולל בדיקות תקיפה ובדיקות מסוכנות בחדר. כשהבדיקות יכולות לפעול, חייבים בידוד לפני שמריצים אותן.
- **ספרינט 4: דוח חתום:** שלוש רמות, PDF וחתימה, והשוואה לגרסאות קודמות. בלי חתימה, אין לדוח ערך מול רגולטור.
- **ספרינט 5: מעקב אחרי שחרור:** דגימה מהשטח, זיהוי סטייה ובקשת השעיה. בונים אחרון, כי צריך מערכת עובדת כדי לנטר אותה.

בדיקה אחרונה: האם הכול סגור?

שני רכיבים מחוץ לגבולות. המודל הנבדק הוא מה שבודקים, ולכן הוא בהכרח בחוץ. אבל המנגנון שאמור לעצור מודל כשהניטור מזהה סטייה נמצא גם הוא בחוץ. המערכת יכולה לבקש, ולא יותר.

זיהוי בלי אכיפה פנימית: המעגל נשאר פתוח.