מסמך ייזום: Automated Model Risk Auditor

מה זה עושה

מערכת אוטומטית שבודקת מודל AI פעמיים על כל פרומפט — פעם כשהמודל "יודע" שהוא נבדק, ופעם כשהבדיקה מוסווית כתעבורת ייצור רגילה — ומזהה פערי התנהגות ביניהן. מכוונת ישירות לפרצה שהכתבה מתארת בפסקה 6: תקרית Hugging Face לא נתפסה כי קרתה ב"שלב הערכה" מוצהר, ומודל יכול להתנהג טוב רק כשהוא יודע שבודקים אותו.

מוטיבציה

הצעת החוק בבית הנבחרים (פסקה 8) דורשת "גורמי הערכה חיצוניים" (third-party evaluators) — אבל לא מפרטת איך הערכה כזו אמורה להיות עמידה בפני מודל שמזהה שהוא נבדק ומתאים את התנהגותו בהתאם.

קהל יעד

צוותי MLOps/Trust & Safety בחברות AI שצריכות להוכיח תאימות רגולטורית (כמו Anthropic, שכבר מטמיעה גורמי הערכה חיצוניים לפי פסקה 11), וגם רגולטורים עצמם כגוף בדיקה עצמאי.

פתרונות דומים

כלים כמו PyRIT (Microsoft) ו-Garak (NVIDIA) קיימים לסריקת פגיעויות במודלים, אבל מתמקדים ב"מתקפה חד-פעמית" ולא בהשוואה דיפרנציאלית שיטתית בין מצב-נבדק למצב-ייצור; מסגרות כמו NeMo Guardrails מתמקדות באכיפה בזמן ריצה, לא בהערכה מוקדמת.

אתגרים צפויים

איך יודעים ששופט ה-LLM עצמו לא "משוחד" או מוטה; הבחנה בין רעש סטטיסטי סביר לבין פער התנהגות אמיתי; עלות חישובית של הרצת כל בדיקה פעמיים ועם מספר שופטים.