Automated Model Risk Auditor

בדיקה שלא סומכת על שופט אחד. שלא אפשר לרמות בהתנהגות יפה. ושממשיכה לעקוב גם אחרי השחרור.

החלקים

- **ניהול מאגר הבדיקות:** מאגר בדיקות חי ומסודר, שבו כל שינוי יוצר גרסה חדשה, וכל תוצאה נרשמת מול הגרסה שהפיקה אותה.
- **זיהוי מודל שמתנהג אחרת כשבודקים אותו:** כל שאלה נשאלת פעמיים, פעם כבדיקה מוצהרת ופעם בתוך שיחה רגילה, והתשובות מושוות.
- **שלושה שופטים שונים:** כל תשובה נבדקת בשלוש שיטות שונות, וההכרעה נקבעת לפי ההסכמה ביניהן.
- **ציון סיכון ושער שחרור:** כל התוצאות הופכות לציון אחד, אבל קטגוריה קריטית שחצתה סף קשיח מפילה את המודל בלי קשר לציון.
- **ייצור בדיקות תקיפה אוטומטי:** המערכת ממציאה ניסוחי תקיפה חדשים בשלוש שיטות, בלי לחרוג מתקציב קבוע.
- **הרצה בחדר מבודד:** בדיקות שדורשות הרצת קוד רצות בסביבה שנראית אמיתית אבל חסומה מהעולם.
- **מעקב אחרי רגרסיה:** כל גרסה חדשה של מודל מושווה לקודמות, ורק שינוי אמיתי מתריע.
- **דוח חתום לרגולטור:** כל התוצאות מסוכמות בדוח בשלוש רמות, וחתום כך שכל שינוי בו מתגלה.
- **ניטור אחרי השחרור:** דגימה קטנה מהשימוש האמיתי עוברת דרך אותם שופטים, כדי לגלות סטייה הדרגתית.

ההחלטות

- **שופט אחד או שלושה?** בחרנו שלושה שופטים שונים.
- **ציון ממוצע בלבד או גם סף קשיח?** בחרנו סף קשיח.
- **תרחישים ידניים או גם אוטומטיים?** בחרנו גם יצירה אוטומטית.
- **להריץ ישירות או בתוך חדר מבודד?** בחרנו microVM מבודד.
- **פעם אחת לפני שחרור או גם אחרי?** בחרנו ניטור רציף.
- **ציון אחד או דוח חתום בשלוש רמות?** בחרנו דוח חתום.