מסמך ייזום: Model Kill-Switch Protocol

מה זה עושה

פרוטוקול "עצירת חירום" מבוזר וקריפטוגרפי, שמאפשר לקבוצת רשויות מוסמכות (M-מתוך-N) לחסום מודל AI ברשת בזמן אמת — בלי לחכות לחקיקה, בלי תלות בגורם יחיד שיכול להיחטף או להישחת, ועם רישום פומבי בלתי-ניתן-להכחשה של כל פעולה. תשובה ישירה לשאלה שמנסחת הכתבה עצמה (פסקה 7): "עד כמה קל לממשל לכבות מודל שיצא משליטה".

מוטיבציה

שלוש הצעות החוק הפדרליות שמתוארות בפסקה 8 — איסור גורף, השהיה מנהלית, חסימת שחרור בצו בית משפט — כולן מנסחות "מתג עצירה" ברמת המדיניות, בלי אף אחת מהן לפרט איך זה קורה טכנית ברמת התשתית.

קהל יעד

מעבדות AI שרוצות (או נדרשות רגולטורית) לספק אמצעי עצירה מהימן; רגולטורים שצריכים ודאות שהעצירה תיאכף בפועל ולא רק על הנייר.

פתרונות דומים

Permissive Action Links (PAL) בעולם הנשק הגרעיני — הרשאה מבוזרת להפעלת נשק, לא לעצירתו, אך אותו עיקרון של "אף גורם יחיד לא מספיק"; Emergency Stop / E-Stop (ISO 13850) בתעשייה — עצירה פיזית מיידית, אך ללא שכבת אימות מבוזרת; Circuit Breakers בשוקי המניות — עצירת מסחר אוטומטית בתנאי סף, אך ללא ממד רב-צדדי של הרשאה.

אתגרים צפויים

מציאת האיזון בין "קל מדי לעצור" (חשיפה להשבתה זדונית או שגויה) לבין "קשה מדי לעצור" (חוזר לבעיה המקורית); הבטחת Fail-Safe אמיתי גם כשהתקשורת המרכזית נופלת; מניעת מצב שבו הרשאה לעצור הופכת בעצמה לוקטור תקיפה (מי שולט על המתג עצמו).