Model Kill-Switch Protocol

עצירה שאי אפשר לזייף. שאי אפשר לנצל נגדך. ושעובדת גם כשהכול סביבה קורס.

החלקים

- **חתימה על כל פקודה:** רק מי שמוסמך יכול לעצור. כל פקודה עוברת ארבע בדיקות לפני שהשער זז.
- **אי-חזרה על פקודות:** פקודה אמיתית שנשלחה פעם אחת לא תעבוד פעם שנייה.
- **השער:** על כל בקשה למודל מחליטים בשבריר שנייה: עוברת או נחסמת.
- **ועדה ולא אדם אחד:** פקודה תקפה דורשת שלושה מתוך חמישה חותמים. מפתח אחד שנגנב לא מספיק.
- **עצירה ממוקדת:** לא תמיד צריך לעצור הכול. אפשר רק מודל אחד, אזור אחד או יכולת אחת.
- **כשהתשתית נופלת:** נפל Redis? נפל Kafka? לכל תחום הוגדר מראש מה עושים: להמשיך או לחסום.
- **שמירה על השומר:** המנגנון מנטר גם את עצמו: מי חתם, כמה ומתי, ומתריע כשמשהו חורג.
- **כמה אזורים:** הפקודה צריכה להגיע לכל אזור שבו המודל רץ, גם כשהקשר בין אזורים נקטע.
- **ספריות למפתחים:** חיבור המנגנון למערכת קיימת בכעשר שורות קוד.
- **הדמיה לפני עצירה:** לפני שחותמים על עצירה אמיתית, רואים בדיוק מה ייפגע.
- **תפוגה אוטומטית:** עצירה שנשכחה לא נשארת לנצח: אחרי ארבע שעות היא חוזרת מעצמה, אלא אם חותמים מחדש.

ההחלטות

- **Ed25519 או RSA?** בחרנו Ed25519.
- **אדם אחד או ועדה?** בחרנו ועדה, 3 מתוך 5.
- **להמשיך או לחסום כשהכול נופל?** בחרנו: תלוי בתחום.
- **AI או סטטיסטיקה?** בחרנו סטטיסטיקה פשוטה.
- **לקטוע או לנקז?** בחרנו לנקז.
- **לעצור לתמיד או לזמן?** בחרנו עצירה עם תפוגה.