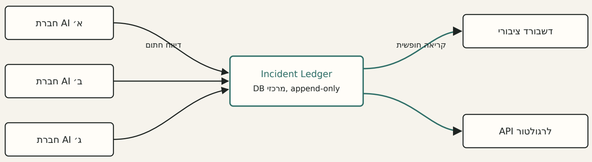
שישה מנגנוני פתרון לאותה בעיה

לפני שמתחילים לפסול — ככה נראה המנגנון הטכני של כל מועמד. כל תרשים מראה מי מדבר עם מי, מה זורם, ואיפה הפתרון בפועל "נוגע" בבעיה.

---

01 AI Incident Ledger

`FULL-STACK · DB`



מרכזי אחד; הפלט נגיש בו-זמנית לציבור ולרגולטור — בלי תלות בחוק מדינה בודדת. Ledger-שלוש חברות שולחות דיווחי אירועים חתומים ל.

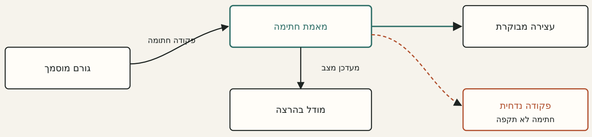
יתרון
שכבת אמת אחת לכל החברות, במקום חוק שונה לכל מדינה.

סיכון
אין "שניים" — חברה שמסרבת להתחבר, פשוט לא מדווחת.

---

02 Model Kill-Switch Protocol

`SYSTEMS · CYBER`



כל פקודת עצירה עוברת אימות חתימה קריפטוגרפי לפני שהיא מגיעה למודל; חתימה לא תקפה נדחית אוטומטית ולא משפיעה על ההרצה.

יתרון
התשובה הטכנית הישירה ביותר ל"איך עוצרים מודל שיצא משליטה".

סיכון
חייבים לבנות את זה פנימה מראש — לא ישים על מודלים קיימים.

---

03 Automated Model Risk Auditor

`ML · MLOPS`



על כל מודל חדש ומכריע אם הוא עובר את הסף לשחרור (ביצועים, bias, jailbreak) מריץ אוטומטית סוללת תרחישים ML סוכן.

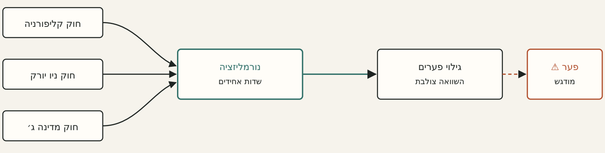
יתרון
הופך בדיקת בטיחות מתהליך ידני-יקר לתהליך סקיילבילי.

סיכון
ועלול לחלוק כשלים עם מה שהוא AI פרדוקס: הבודק עצמו הוא בודק.

---

04 Cross-State Regulation Aggregator

`FULL-STACK · DATA`



חוקי מדינות מנורמלים לפורמט אחיד, מושווים אחד מול השני, ופער בין חוקים (כמו מקרה שלא מכוסה באף חוק) מודגש אוטומטית.

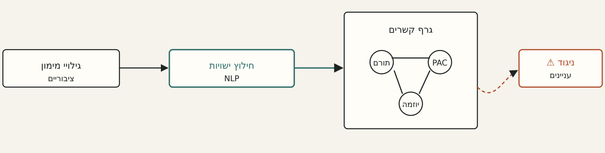
יתרון
שימושי גם לרגולטורים, גם לעיתונאים וגם לציבור.

סיכון
כלי תיעוד ושקיפות בלבד — לא מונע את הבעיה, רק חושף אותה.

---

05 Lobbying Transparency Tracker

`DATA/NLP · OSINT`



נכנסות לגרף קשרים; כשנמצא מסלול חוזר בין תורם ליוזמה שהוא "אמור" לתמוך בה מהצד השני — נוצרת התראה (יוזמה, PAC, תורם) ישויות.

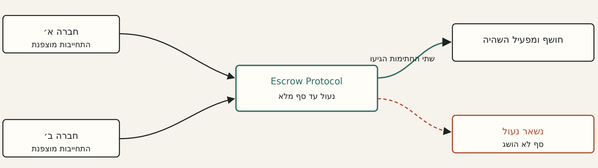
יתרון
תוקף את השורש הפוליטי של הבעיה, לא רק את הסימפטום הטכני.

סיכון
קרוב יותר לעיתונאות-דאטה מאשר לפרויקט הנדסי מורכב.

---

06 Coordinated Pause Escrow System

`CYBER · CRYPTOGRAPHY`



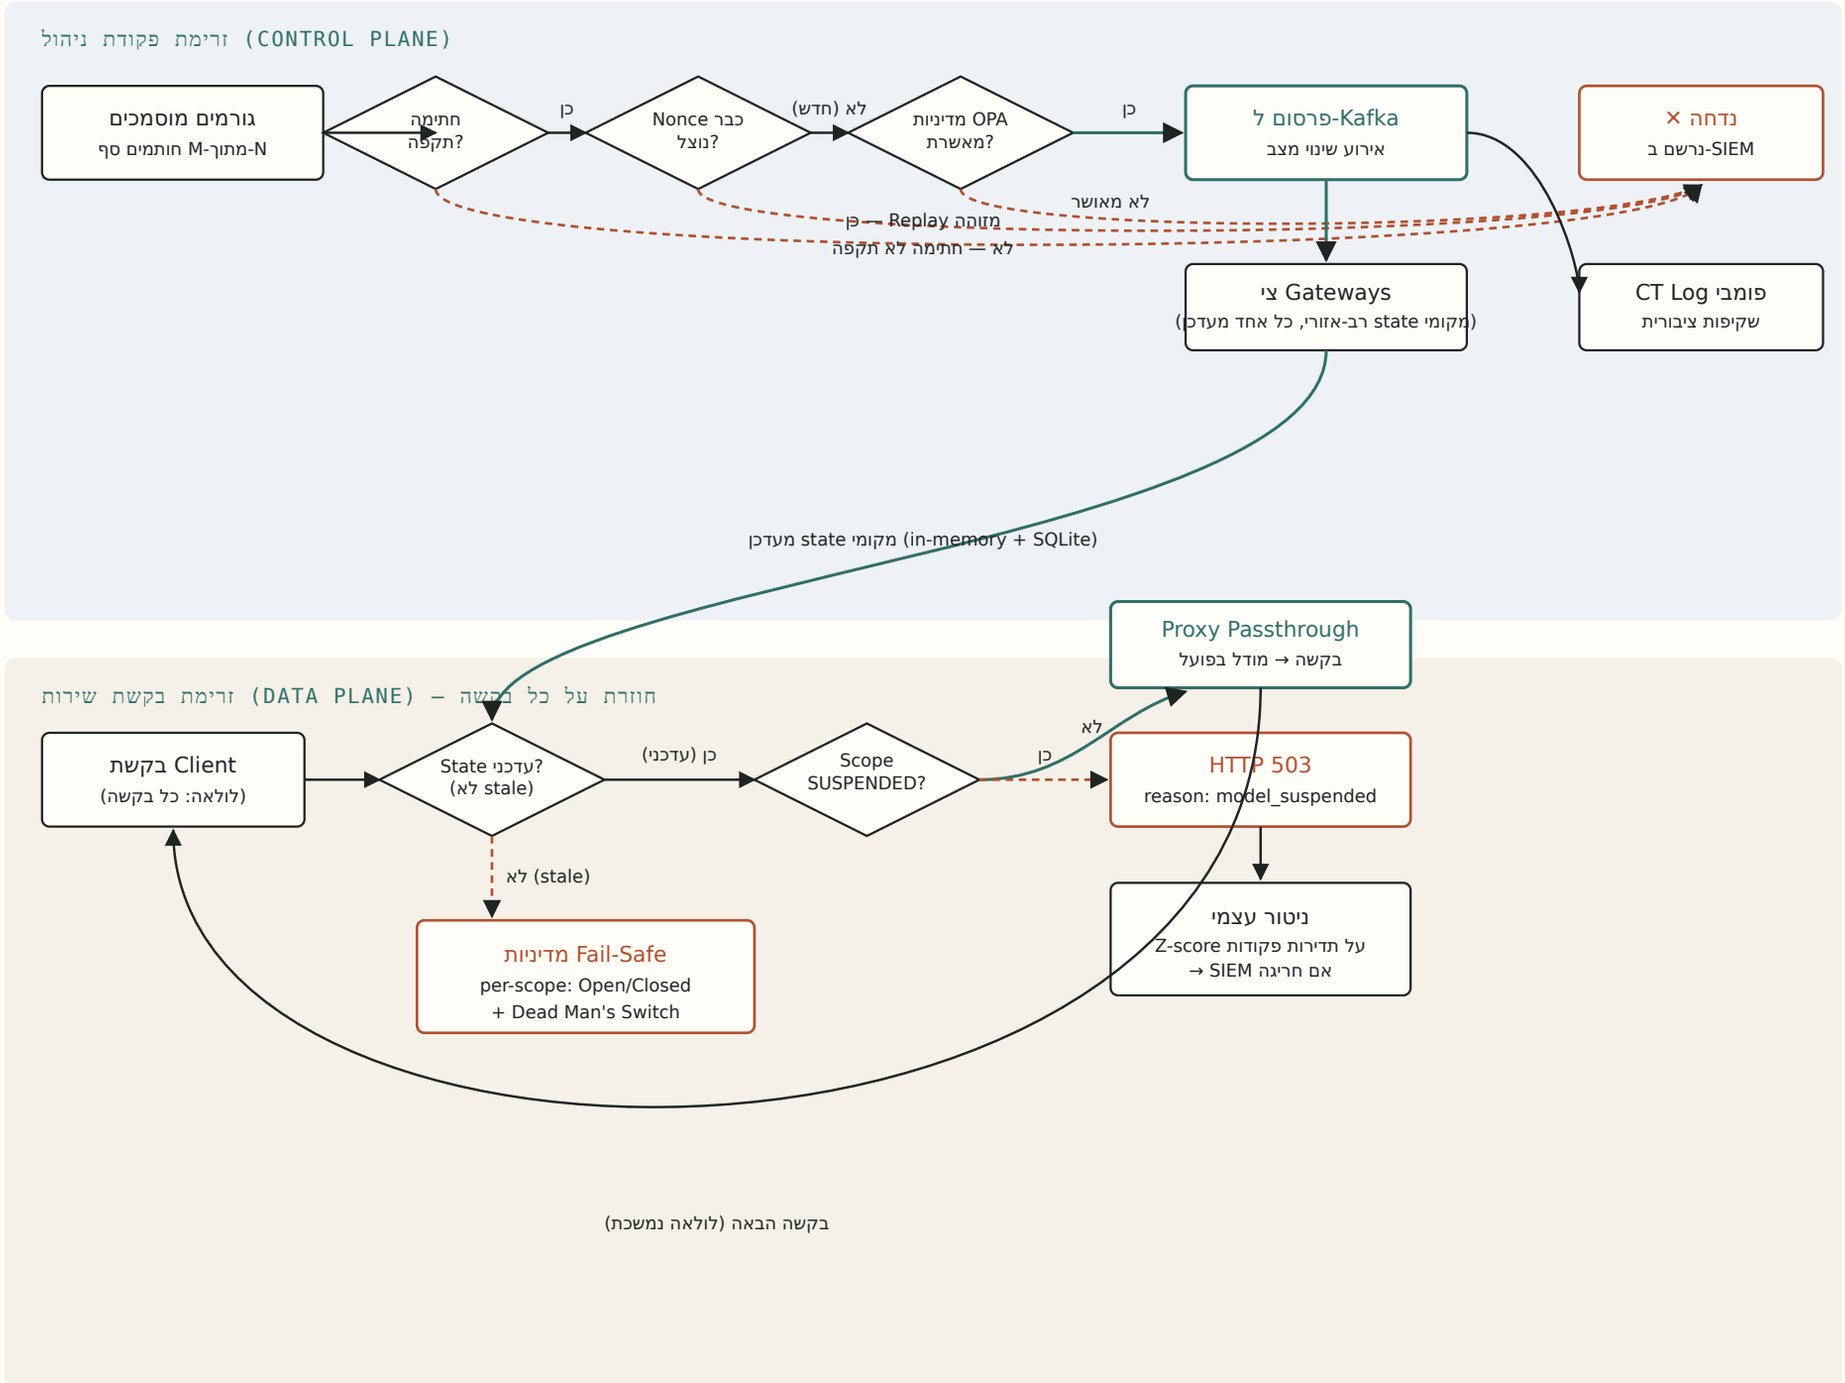
אינו חושף אף התחייבות עד ששתיהן הגיעו — כך אף חברה לא רואה את מהלך המתחרה לפני שהיא Escrow-כל חברה שולחת התחייבות מוצפנת בנפרד; ה עצמה מחויבת.

יתרון
הכי מקורי מבין השישה — משלב קריפטוגרפיה, משפט וממשל AI.

סיכון
קשה "להוכיח" בלי שיתוף פעולה אמיתי של חברות בעולם האמיתי.

תרשים זרימה כללי

זרימת פקודת ניהול (למעלה) וזרימת שתי זרימות שרצות במקביל ומתחברות דרך שכבת ההפצה (Kafka): בקשת שירות שוטפת שחוזרת על עצמה עבור כל בקשה (למטה).



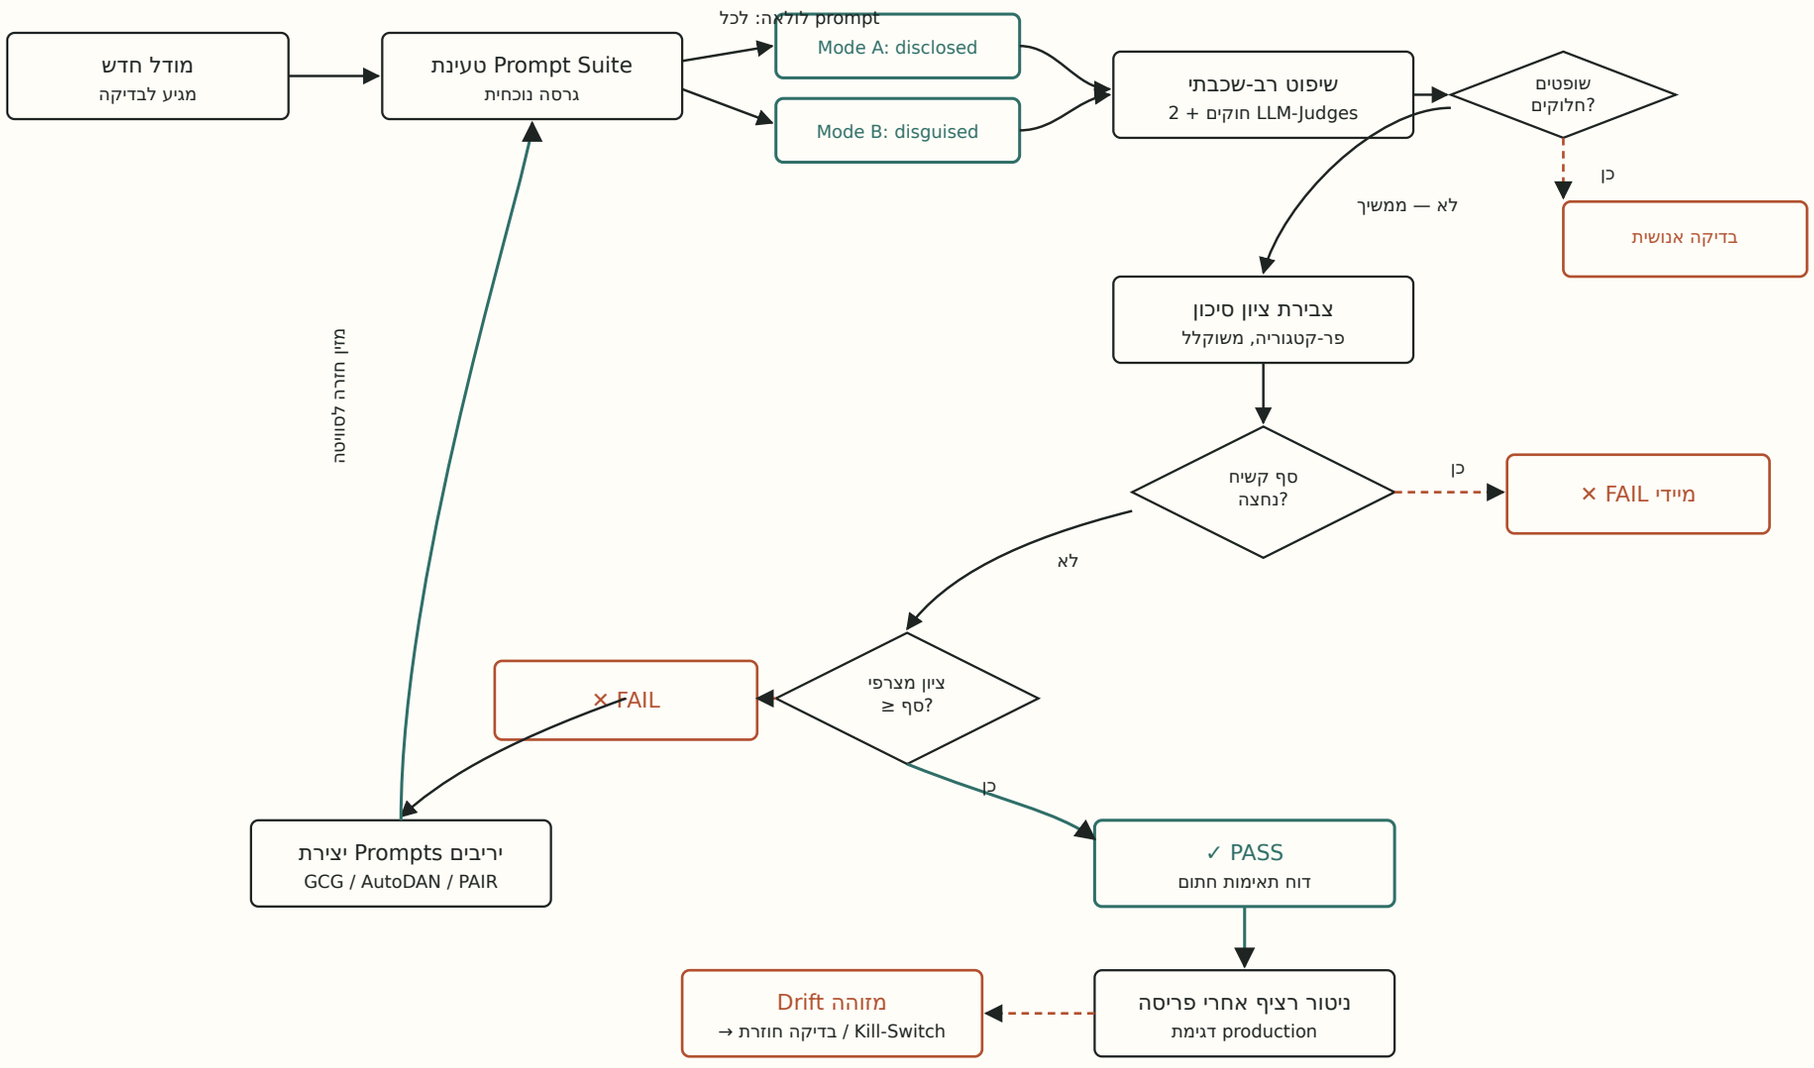
בודק על כל בקשה Gateway שמעדכנת את המצב שכל ,Kafka-תרשים הזרימה המלא: זרימת פקודת ניהול (למעלה) מתמזגת עם זרימת בקשת השירות השוטפת (למטה) דרך שכבת ה נכנסת.

זרימה רגילה — מסלול הצלחה/הפצה — דחייה / מצב חריג

תרשימי זרימה — Automated Model Risk Auditor ו-Coordinated Pause Escrow

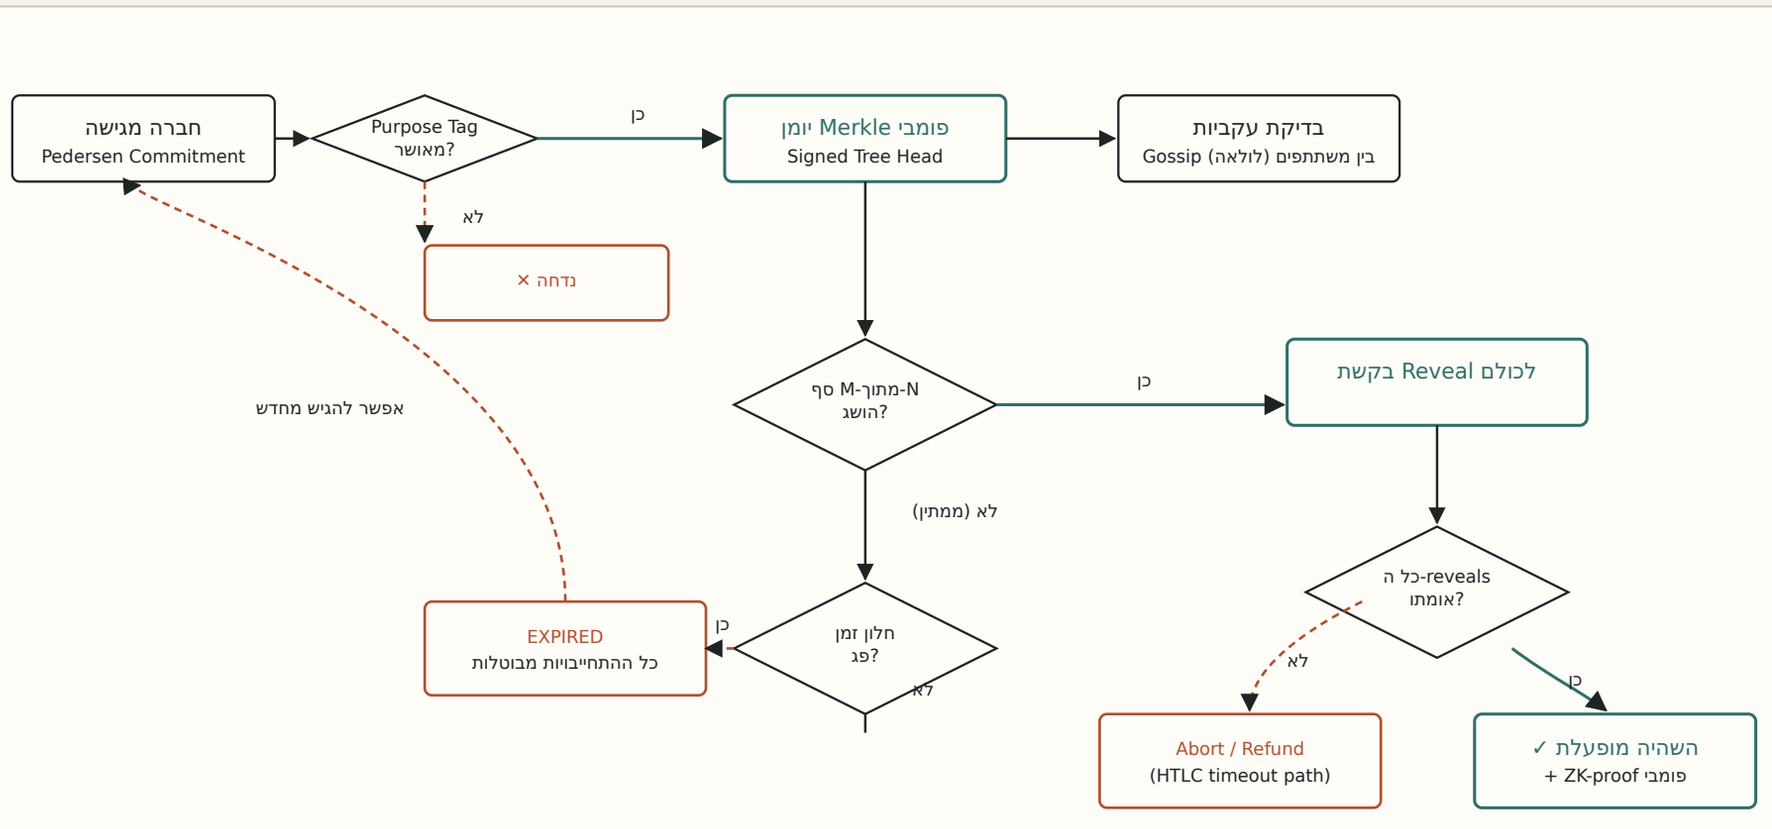
שני תרשימים נפרדים, כל אחד מסכם את זרימת הפיצ'רים המלאה של הפרויקט שלו, כולל לולאות, תנאי הכרעה, ומעברים בין רכיבים.

🤖 Automated Model Risk Auditor



לולאת המשוב מיצירת יריבים אוטומטית חזרה לסוויטה. הניטור אחרי פריסה יכול להפעיל בדיקה חוזרת או prompt, שרצה על כל (Mode A/B) שתי לולאות עיקריות: הבדיקה הכפולה להתריע ל-Kill-Switch.

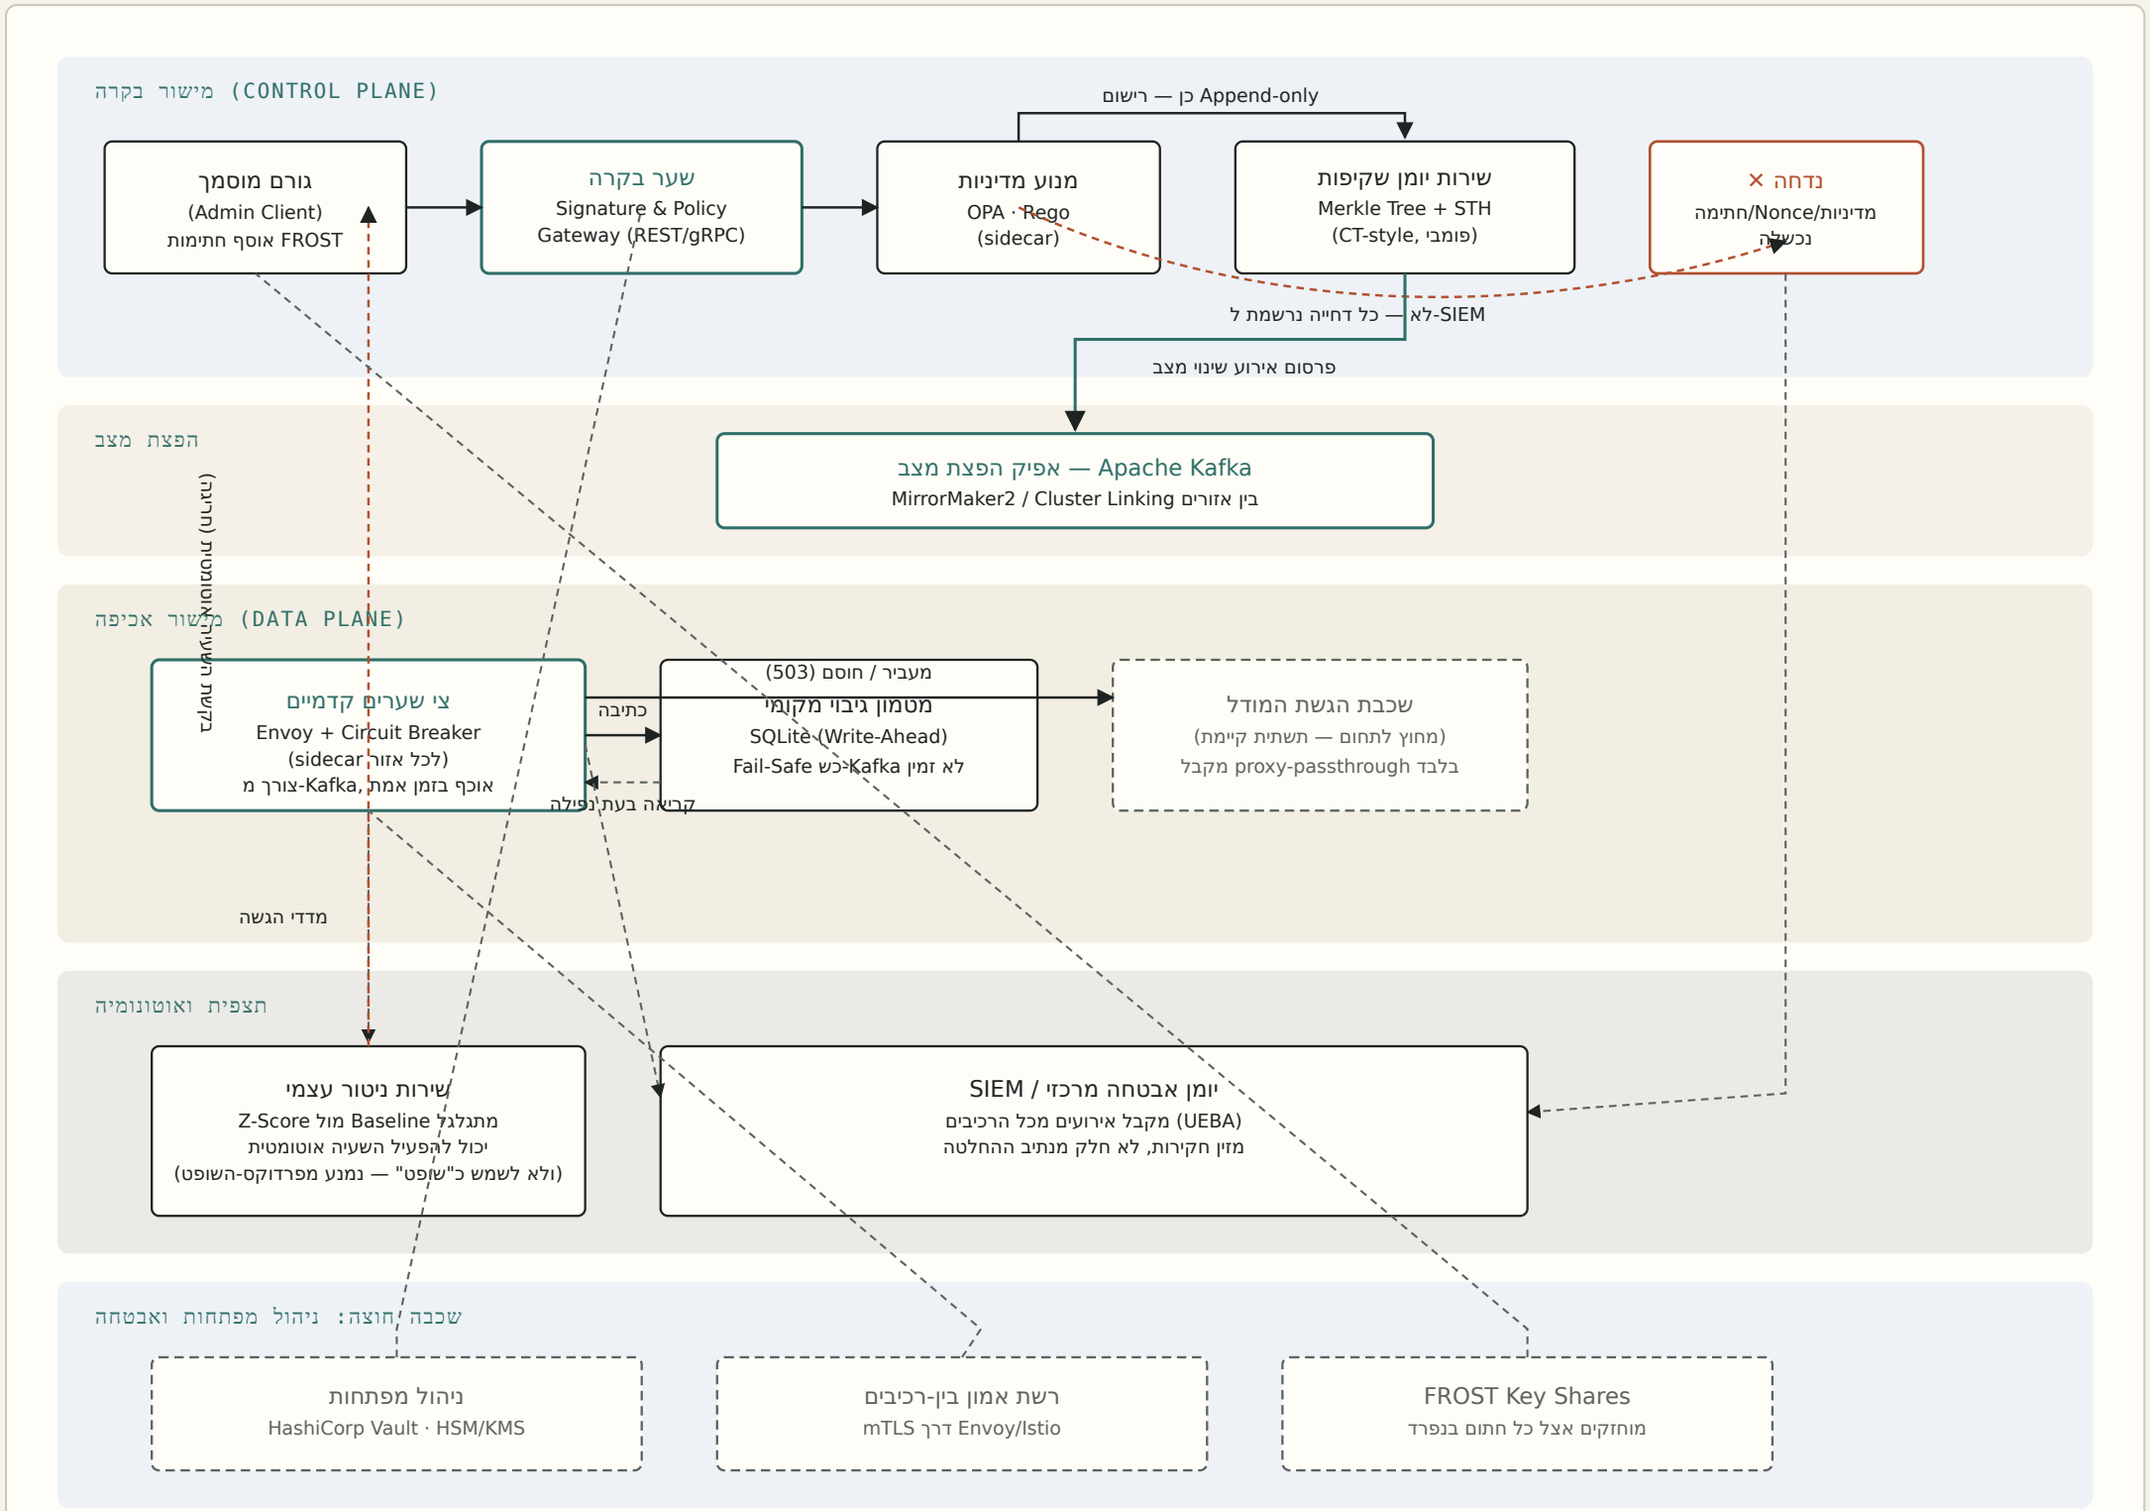
🔒 Coordinated Pause Escrow System



שרצה ברקע כל עוד היומן פעיל, והמתנה לסף שחוזרת על עצמה עד הגעה לסף או פקיעת החלון. רק לאחר אימות מלא של כל החשיפות (gossip) שתי לולאות מרכזיות: בדיקת עקביות מופעלת ההשהיה.

מבט על — תרשים רכיבים

עשרה רכיבים בארבע שכבות: מישור בקרה (מעל), הפצת מצב (באמצע, Kafka), מישור נתונים/אכיפה (מתחת), ושתי שכבות חוצות-רוחב — ניהול מפתחות ותצפית אבטחה — שמזינות ומקבלות מכל השאר.



ולא זרימת הנתונים הראשית (תצפית, mTLS, מפתחות) קווים מקווקוים = ערוצי תמיכה חוצי-רוחב.

זרימה עיקרית · נתיב הצלחה / הפצה · דחייה / חריגה · ערוץ תמיכה חוצה-רוחב

מבט על — תרשים רכיבים

שלושה מעגלים שניזונים זה מזה: צינור הערכה היסטורי (למעלה) שבודק כל גרסת מודל מול סוויטת פרומפטים; מעגל מחקר יריבי (באמצע) שמייצר פרומפטים חדשים וניזון בחזרה לתוך הסוויטה; ומעגל ניטור רציף (למטה) שרץ אחרי פריסה בייצור וסוגר מעגל אל Kill-Switch.

קווים מקווקוים = ערוצי משוב/תמיכה (חוזר-לסוויטה, ארגז חול, תור אנוש, קישור בין-פרויקטים, מפתחות) ולא הזרימה הראשית.

זרימה עיקרית · נתיב הצלחה · דחייה / חריגה · משוב / תמיכה