Case 03 · מסמך ייזום: Removal Sample Audit

לפי פרק 1 (ייזום) בתבנית תיק הפרויקט של מגשימים. לכל פרויקט: תיאור כללי, מטרה, קהל יעד, פתרונות קיימים, ליבה טכנולוגית, טכנולוגיות, אתגרים ומקורות, דרישות חומרה, ומסקנה.

תיאור כללי

מערכת שמודדת כמה מהמחיקות מפנקס הבוחרים היו שגויות, בלי לבדוק את כולן. בכל מחוז היא בוחרת מדגם אקראי של כמה מאות מחיקות, שולחת כל מקרה לבדיקה מלאה (האם האדם עדיין גר כאן, חי, ורשום פעם אחת), ומחשבת מהתוצאה את שיעור המחיקות השגויות בכל המחוז, עם טווח טעות ידוע.

בפועל: במקום ויכוח פוליטי על "כמה נמחקו בטעות", כל מחוז מקבל מספר אחד שאפשר לבדוק: "11% ±1.8 מהמחיקות כאן שגויות". מחוז שבו המספר גבוה נכנס לבדיקה מחודשת של כל המחיקות שלו, לפני הבחירות.

מטרת הפרויקט

בחרנו בפרויקט כי בסיפור יש שני מחנות שמדברים על אותו מספר, 130 מיליון, ומסיקים ממנו הפוך. התומכים אומרים שרובם מתים, כפולים ומהגרים. המבקרים אומרים שזו גניבה. שניהם צודקים חלקית, ואף אחד לא יודע כמה. מצד שני, הנתון היחיד שיש, שרוב הערעורים שהוכרעו הצליחו, מרמז שהשגיאה לא קטנה.

המטרה: להחליף ויכוח במדידה. סטטיסטיקה של מדגם היא כלי ותיק, זול ומובן, ואפשר להריץ אותה מהר, לפני שהבחירות מגיעות.

קהל היעד

- קהל עיקרי: ועדת הבחירות ובתי המשפט, שצריכים לדעת אם רוויזיה מסוימת אמינה מספיק כדי לקיים עליה בחירות. ידע נדרש: הבנה בסיסית של מדגם וטווח טעות.
- קהל משני: מפלגות, עיתונאים וחוקרים, שרוצים מספר שאפשר לשחזר ולא רק להאמין לו.
- תרחיש להמחשה: בבנגל המערבית יש 37 לאך ערעורים ממתינים. במקום לחכות לכולם, ועדת הבחירות מריצה מדגם של 1,500 מחיקות בכל מחוז תוך שבועיים, ומגלה באילו מחוזות צריך לעצור ולבדוק הכול.

פתרונות קיימים

- **Risk-Limiting Audits** (ארה"ב): ביקורת מדגם של פתקי הצבעה כדי לאשר שתוצאת הבחירות נכונה, בשימוש בכמה מדינות בארה"ב. מוכיח שמדגם סטטיסטי מתקבל כבסיס חוקי לאמון בבחירות, אבל על הספירה ולא על הרשימה.
- ביקורות רשימה של ארגוני חברה אזרחית בהודו: בדיקות שטח מדגמיות של רשימות הבוחרים בידי ארגונים כמו ADR וחוקרים עצמאיים. מוכיחות שהשיטה עובדת, אבל הן חד-פעמיות, בלי שיטה אחידה ובלי מעמד.
- בדיקות איכות של ועדת הבחירות עצמה: ביקורי בית של עובדי הקלפי (BLO) לאימות. קיימות, אבל אינן מדגם אקראי ואינן מפרסמות טווח טעות.

מה מייחד אותנו: מדגם אקראי שאפשר לשחזר (הגרלה ציבורית מ-seed ידוע), מפורק לפי סיבת המחיקה, עם פרסום של השיטה, ה-seed והתוצאה.

ליבה טכנולוגית

הליבה היא מנוע הדגימה והאומדן: הגרלה אקראית שאפשר לבדוק מחדש מ-seed ציבורי, דגימה מרובדת לפי סיבת מחיקה, ואומדן עם רווח סמך (Wilson) לכל מחוז ולכל סיבה. בלי המנוע הזה אין פרויקט: כל השאר (ממשק לבודקים, דוחות, מפה) בנוי עליו.

טכנולוגיות עיקריות

- **Python** עם **NumPy** ו-**SciPy**: לחישובי מדגם ורווחי סמך. בחרנו כי הם מתועדים ונבדקו היטב.
- הגרלה ציבורית מ-**seed** ידוע (למשל ממספרי הגרלה או מ-**randomness beacon**): כדי שכל אחד יוכל לשחזר אילו מקרים נבחרו.

- אפליקציית שטח (**Android**, עבודה בלי רשת): לבודקים שמבקרים בבתים ומתעדים.
- **PostgreSQL** ו-**Superset**: לאחסון התוצאות ולמפה של מחוזות.

מתלבטים:

- מדגם פשוט מול מרובד: מרובד מדויק יותר כשסיבות המחיקה שונות מאוד בשיעור השגיאה שלהן, אבל דורש מדגם גדול יותר בסך הכול.
- בדיקה בשטח מול בדיקה בטלפון: טלפון זול ומהיר, אבל מי שנמחק כי "עבר דירה" אולי לא עונה למספר הישן.

אתגרים טכנולוגיים ומקורות מידע

- מקור האמת בשטח: האם האדם עדיין גר כאן? את זה יודעים רק מביקור. מי מבקר, ועל מי הוא סומך? זה האתגר המרכזי.
- גישה לרשימת המחיקות: צריך את הרשימה המלאה של מחוז כדי להגריל ממנה. אחרי ההוראה של בית המשפט העליון בביהאר (2025), רשימות כאלה פורסמו.
- קנה מידה: מאות מחוזות × 1,500 מקרים = מאות אלפי ביקורים. גדול, אבל קטן בהרבה מ-130 מיליון.

מקורות: "Stark, "Risk-Limiting Postelection Audits"; ספרות דגימה מרובדת (Cochran, Sampling Techniques); הוראת בית המשפט העליון לגבי ביהאר (אוגוסט 2025).

דרישות חומרה

אין חומרה מיוחדת. ל-POC מספיק מחשב אחד. בפריסה: טלפונים לבודקי שטח ושרת מרכזי.

מסקנה

✅ שורד. השיטה ותיקה ומוכרת, הקלט זמין ציבורית, והתוצאה ברורה. ההתניה: מקור האמת בשטח. בשלב המחקר צריך לבדוק עד כמה האומדן רגיש לבודק שלא בודק באמת.