POC: Removal Sample Audit-ו מחקר · Case 03

לפי תבנית "מחקר ו-*POC*" של מגשימים. ה-*POC* נכתב בפייתון והורץ בפועל, והמספרים כאן הם הפלט שלו. כתוב במפורש מה אמיתי ומה מדומה.

מחקר בסיסי: רצף האירועים

- הגרלה: מ-seed ציבורי (מפורסם מראש) מגרילים במחוז 1,500 מחיקות מתוך רשימת המחוקים.
- שיבוץ: כל מקרה משובץ לבודק שטח.
- בדיקה: הבודק מבקר בכתובת, ומסמן: האדם גר כאן וזכאי (מחיקה שגויה), או שהמחיקה נכונה (נפטר, עבר, כפול).
- אומדן: מחשבים את שיעור המחיקות השגויות ורווח סמך של 95%, בסך הכול ולפי סיבה.
- החלטה: מחוז מעל סף מוגדר (למשל 5%) נכנס לבדיקה מלאה.

מחקר בסיסי: רכיבי המערכת

- **Sampler**: הגרלה שאפשר לשחזר.
- **Field App**: אפליקציה לבודקים, עובדת בלי רשת.
- **Estimator**: אומדן ורווחי סמך.
- **Dashboard**: מפה של מחוזות.

מחקר בסיסי: אתגרי אבטחה

- הגרלה מוטה: מי שמגריל יכול לבחור מקרים "נוחים". ההגנה: seed ציבורי ושיטה מפורסמת.
- בודק שלא בודק: בודק שמסמן "המחיקה נכונה" בלי לבקר. זה הסיכון המרכזי, ומעבדה 4 מודדת אותו.
- בודק עם אינטרס: אם הבודקים שייכים לאותו מנגנון שמחק, יש להם אינטרס לאשר.

מחקר בסיסי: השוואה למתחרה המוביל (ביקורי בית של עובדי הקלפי)

- אקראיות: ביקורי בית היום לא אקראיים. אצלנו אקראיים, עם seed ציבורי.
- מספר אחד: היום אין מספר מסכם. אצלנו יש שיעור וטווח טעות.
- עלות: אנחנו בודקים 1,500 מקרים במחוז, לא מאות אלפים.

מחקר בסיסי: סוגיה אתית

מספר כמו "11% שגויות" יכול להפוך לכותרת פוליטית. לכן מפרסמים תמיד את הטווח, את השיטה ואת ה-seed, ולא רק את המספר.

חמישה פיצ'רים מרכזיים

- הגרלה מ-**seed** ציבורי: קלט: רשימת מחיקות ו-seed. פלט: רשימת מקרים. איך: `random.Random(seed).sample`.
- ריבוד לפי סיבה: קלט: רשימת מחיקות. פלט: מדגם לכל סיבה. איך: הקצאה לפי גודל כל רובד.
- אומדן **Wilson**: קלט: k שגויות מתוך n. פלט: שיעור ורווח סמך. איך: נוסחת Wilson ב-95%.
- בדיקת כיסוי: קלט: מחוז מדומה עם אמת ידועה. פלט: באיזה אחוז מההרצות הטווח מכיל את האמת.
- רגישות לבודק: קלט: הסתברות שבודק "מאשר" מחיקה שגויה. פלט: הטיית האומדן.

שאלת המחקר: ה-POC

האם מדגם של כמה מאות מחיקות במחוז נותן אומדן מדויק ואמין לשיעור המחיקות השגויות, ועד כמה הוא רגיש למי שבודק בשטח?

טכנולוגיות ומגבלות: ה-POC

- פייתון טהור (`random`, `math`), כדי שירוץ בדפדפן.
- מגבלה חשובה: המחוזות, המחיקות ושיעורי השגיאה האמיתיים מדומים (מחוז של 120,000 מחיקות; 70% בסל "נעדר, עבר או אחר"; שיעורי שגיאה: נפטר 3%, כפול 8%, סל 19%). הסטטיסטיקה אמיתית.

ה-POC: תוצאות

מעבדה	מה מדדנו	תוצאה
דיוק	גודל מדגם מול טווח טעות (אמת: 14.8%)	100: ±8.4 · 600: ±2.8 · 1,500: ±1.7 · 3,000: ±1.3
כיסוי	2,000 ביקורות של 1,500 מקרים	הטווח הכיל את האמת ב-94.8% (מצופה 95%), טווח ממוצע ±1.8
ריבוד	סיבה אחת מול שלוש	נפטר 3.2% (אמת 3.0), כפול 9.2% (8.3), סל 19.4% (18.9)
שטח	בודק ש"מאשר" חלק מהמחיקות השגויות	0%: 14.8% (כיסוי 95%) · 10%: 13.2% (63%) · 25%: 11.0% (1.8%) · 40%: 8.7% (0%)

ה-POC: מסקנות

- ✅ דיוק וכיסוי: הוכחו. 1,500 מקרים נותנים טווח של כ-±1.8 נקודות, והטווח אמין.
- ✅ ריבוד: הוכח, ומראה שהסל המעורבב הוא המקום שבו רוב הטעויות.
- ⚠️ שטח: הממצא שמלווה את הרעיון מכאן. האומדן מדויק רק כמו הבודק. אם רבע מהמחיקות השגויות "מאושרות" בלי בדיקה אמיתית, האומדן יורד מ-14.8% ל-11%, והטווח מכיל את האמת רק ב-1.8% מהמקרים. הסטטיסטיקה לא מגינה מפני זה, היא רק נראית בטוחה.

מסקנה: ✅ שורד, ועובר לאפיון. השאלה הפתוחה: מי יהיה מקור האמת בשטח.